

Introducción a Series temporales

Modelos AR, MA, ARMA, ARIMA, GARCH

Georgina Flesia, Patricia Kisbye
FaMAF.

26 de noviembre de 2022

Qué es una serie de tiempo

Series de tiempo:

Una **serie de tiempo** es un conjunto de datos indexados con un orden temporal:

$$(x_t)_{t \in T}, \quad T \subset \mathbb{R}$$

- T discreto: serie temporal discreta.
- T un intervalo real: serie temporal continua.

Ejemplos de series de tiempo

- Precios de productos financieros, índices, tasas de interés, inflación, PBI, etc.
- Producción anual de trigo, maíz, exportaciones, etc.
- Población, tasas de natalidad, mortalidad, accidentes, crímenes,
- Medicina: electrocardiograma, encefalogramas, etc.
- FAMAf: cantidad de inscriptos, alumnos, egresados, etc. por año.

Estudiar series

Objetivos:

- Modelos probabilísticos que permitan entender y describir los procesos aleatorios que generan la serie temporal.
- Predicción de valores futuros.
- Control de procesos.

Características de una serie de tiempo

- La serie $x_1, x_2, x_3, \dots, x_T$:
 - ▶ una muestra de tamaño 1 de un proceso estocástico, o
 - ▶ T observaciones de T variables aleatorias, no independientes.
- La dependencia entre los valores de la serie no permite aplicar el análisis estadístico usual.
- Para definir algunos modelos estadísticos, una primera aproximación es suponer estacionariedad de la serie, es decir, que la serie se *comporte siempre igual*.
- ¿Qué significa que sea **estacionaria**?

Serie de retornos

La mayoría de los estudios financieros involucran retornos de activos, en lugar de precios:

- El retorno del activo es una síntesis completa y libre de escalas de la oportunidad de inversión.
- La serie de retornos es más manejable que la de precios, por tener mejores propiedades.

Definición de retorno

- Retorno simple:

$$R_t = \frac{P_t - P_{t-1}}{P_{t-1}} = \frac{P_t}{P_{t-1}} - 1$$

- Retorno compuesto:

$$1 + R_t[k] = \frac{P_t}{P_{t-1}} \times \frac{P_{t-1}}{P_{t-2}} \times \dots \times \frac{P_{t-k+1}}{P_{t-k}}$$

- Retorno continuo:

$$e^{r_t} = \frac{P_t}{P_{t-1}}$$

$$1 + R_t = \frac{105}{100}$$

$$R_t = 0,05$$

$$e^{r_t} = \frac{105}{100}$$

$$r_t = 0,048 = \ln(1 + 0,05)$$

La distribución de los retornos

Algunas hipótesis que se suelen proponer en relación a los retornos:

- Retornos simples independientes e igualmente distribuidos, con media y varianza constante.
- Log retornos independientes e igualmente distribuidos con media μ y varianza σ^2 . [Modelo de Black Scholes](#).
- Retornos con mezcla de distribuciones.

Series estacionarias


Serie de tiempo: $x_1, x_2, x_3, \dots, x_T$

Proceso estrictamente estacionario

La distribución conjunta de $(x_{t_1}, x_{t_2}, \dots, x_{t_k})$ es la misma que la distribución conjunta de $(x_{t_1+h}, x_{t_2+h}, \dots, x_{t_k+h})$ para cualquier subconjunto $(x_{t_1}, x_{t_2}, \dots, x_{t_k})$. Sólo puede depender de h .

En la práctica son procesos difíciles de encontrar.

Estacionariedad



Proceso (débilmente) estacionario

$E[x_t] < \infty$, $Var(x_t) < \infty$, y:

- $E[x_t] = \mu$, es una constante independiente de t .
- $Cov(x_t, x_{t+h}) = \gamma_h$, depende de h , no de t .

- γ_h : Autocovarianza del retardo h .
- ρ_h : Autocorrelación del retardo h

$$\rho_h = \frac{Cov(x_t, x_{t+h})}{\sqrt{Var(x_t)}\sqrt{Var(x_{t+h})}} = \frac{\gamma_h}{\gamma_0} \quad -1 \leq \rho_h \leq 1.$$
$$\rho_0 = 1.$$

```
import statsmodels.tsa.api as stm
...
stm.graphics.plot_acf(serie, lags = 20)
```




Figura: Función de autocorrelación

Si la serie es estacionaria y $\lim_{h \rightarrow \infty} \rho_h = 0$ (condición suficiente), entonces existen estimadores consistentes:

- $\hat{\mu}$ para la media:

$$\hat{\mu} = \frac{1}{T} \sum_{t=1}^T x_t$$

- $\hat{\gamma}_h$ para las autocovarianzas:

$$\frac{1}{T} \sum_{t=1}^{T-h} (x_t - \hat{\mu})(x_{t+h} - \hat{\mu}).$$

```
import quandl
quandl.get("NSE/SPYL", start_date="2011-01-12", end_date="2013-01-01")
```




Figura: Función de autocorrelación

Ruido blanco

Ruido blanco

Es un proceso a_t con las siguientes propiedades:

- Media 0: $E[a_t] = 0$.
- Varianza finita constante: $Var(a_t) = \sigma_a^2 < \infty$.
- Autocovarianzas nulas: $Cov(a_t, a_{t+h}) = 0$ para $h \neq 0$.
- Si cada a_t tiene distribución normal: $a_t \sim N(0, \sigma_a)$, se trata de un **Ruido blanco Gaussiano**.

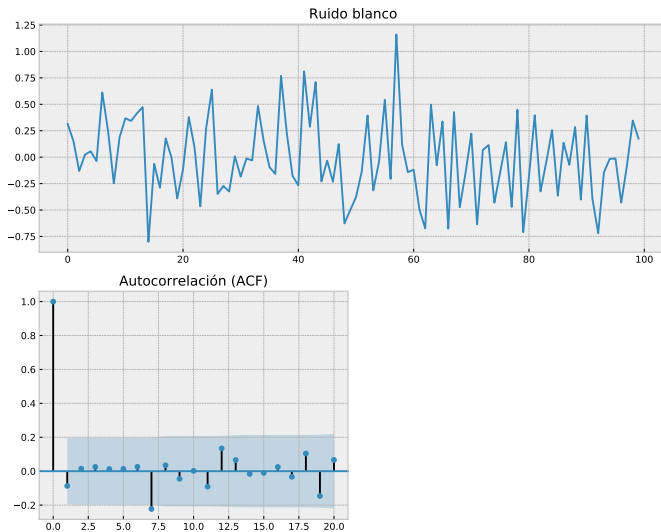


Figura: Ruido blanco

Series de tiempo lineales

Series lineales

Son las series que pueden escribirse como

$$x_t = \mu_t + a_t + \psi_1 a_{t-1} + \psi_2 a_{t-2} + \dots,$$

donde μ_t es la media y $\{a_t\}$ es un ruido blanco.

- a_t : es la **innovación** del proceso en tiempo t .
- Para las series lineales débilmente estacionarias $\mu_t = \mu$.

Teorema de Wold: Toda serie estacionaria con media 0 y sin componente determinística puede escribirse de esa forma, con la condición:

$$\sum_{j=1}^{\infty} |\psi_j| < \infty.$$

Caminata aleatoria

Caminata aleatoria

Es un proceso estocástico x_t que satisface:

$$x_t = x_{t-1} + a_t,$$

donde a_t es un ruido blanco.

Notamos que:

$$x_t = x_{t-1} + a_t = x_{t-2} + a_{t-1} + a_t = x_{t-3} + a_{t-2} + a_{t-1} + a_t = \dots$$

$$x_t = x_0 + a_t + a_{t-1} + \dots + a_1 = x_0 + \sum_{j=0}^{t-1} a_{t-j}$$

- No es estacionaria. Tiene una tendencia estocástica: $\text{Var}(x_t) = t\sigma_a^2$.




Figura: Caminata aleatoria

Ejemplo

Ejemplo

$$x_t = rx_{t-1} + a_t$$

a_t un ruido blanco.

$$\begin{aligned}x_t &= rx_{t-1} + a_t = r(rx_{t-2} + a_{t-1}) + a_t \\&= r^2x_{t-2} + ra_{t-1} + a_t = r^2(rx_{t-3} + a_{t-2}) + ra_{t-1} + a_t \\&= r^3x_{t-3} + r^2a_{t-2} + ra_{t-1} + a_t\end{aligned}$$

$$x_t = r^t x_0 + \sum_{j=0}^{t-1} r^j a_{t-j}$$

- Si $|r| < 1$ la suma $\sum_j r^j$ es convergente.
- Si $|r| < 1$ la serie es estacionaria.

Modelos Autorregresivos

- $AR(p)$. El valor de x_t depende de observaciones anteriores: $x_{t-1}, x_{t-2} \dots$
- $MA(q)$. Las observaciones dependen linealmente de innovaciones anteriores: a_{t-1}, a_{t-2}, \dots
- $ARMA(p, q)$. Combinaciones de ambas
- **Series integradas $I(p)$** . No estacionarias, pero sus diferencias $x_t - x_{t-1}$ (o de orden mayor) sí.
- $ARIMA(p, I, q)$. Combinaciones de las tres.
- **ARCH(p), GARCH(p,q)**. Las innovaciones a_t condicionales no tienen varianza constante.
- Muchos otros.

Modelos AR(p)

$$AR(p)$$

- Son modelos **A**uto**R**egresivos, de orden p .
- Estos modelos intentan explicar la i -ésima observación a partir de las observaciones anteriores.
- Según el número de observaciones anteriores consideradas es el orden p .

$$x_t = \phi_0 + \phi_1 x_{t-1} + a_t \quad AR(1)$$

$$x_t = \phi_0 + \phi_1 x_{t-1} + \phi_2 x_{t-2} + a_t \quad AR(2)$$

- a_t : innovación, es un ruido blanco.

Modelo $AR(1)$

$$x_t = \phi_0 + \phi_1 x_{t-1} + a_t$$

- **Predicción:** Dado x_{t-1} , el valor **esperado** de x_t es $\phi_0 + \phi_1 x_{t-1}$:

$$\hat{x}_t = E[x_t \mid \text{tiempo pasado}] = \phi_0 + \phi_1 x_{t-1}$$

- Si la serie es estacionaria:

$$\mu = \frac{\phi_0}{1 - \phi_1} \qquad x_t - \mu = \phi_1(x_{t-1} - \mu) + a_t$$

- Restando la media μ se trabaja directamente con:

$$y_t = \phi_1 y_{t-1} + a_t.$$

- Es estacionario si y sólo si $|\phi_1| < 1$.

Modelo $AR(p)$ - Autocorrelaciones

- La ACF de un $AR(1)$ es

$$\rho_h = \phi_1^h, \quad h > 0.$$

- Para un $AR(2)$: $\rho_h = \phi_1 \rho_{h-1} + \phi_2 \rho_{h-2}, \quad h > 2.$
- La ACF no da demasiada información para distinguir un $AR(p)$.

Autocorrelación parcial (PACF)


Es la correlación entre x_t y x_{t+l} quitando la dependencia sobre $x_{t+1}, x_{t+1}, \dots, x_{t+l-1}$.

- Si es un $AR(p)$, se anulan todas las autocorrelaciones parciales desde $p + 1$ en adelante.


Modelo AR(1)

```
phi = 0.6  
ar = np.r_[1, -phi], ma = np.r_[1,0]  
ar1 = smt.arma_generate_sample(ar=ar, ma=ma, nsample=n)
```


Análisis gráfico de serie temporal



Autocorrelación




Autocorrelación parcial




Modelo AR(1)

```
phi = -0.6  
ar = np.r_[1, -phi], ma = np.r_[1,0]  
ar1 = smt.arma_generate_sample(ar=ar, ma=ma, nsample=n)
```


Análisis gráfico de serie temporal



Autocorrelación



Autocorrelación parcial



Propiedades $AR(2)$

$$x_t = \phi_0 + \phi_1 x_{t-1} + \phi_2 x_{t-2} + a_t$$

- Si es débilmente estacionario: $\mu = \frac{\phi_0}{1-\phi_1-\phi_2}$
- Función de autocorrelación ACF: $\rho_l = \phi_1 \rho_{l-1} + \phi_2 \rho_{l-2}$.
- Para que sea débilmente estacionaria, las raíces de

$$1 - \phi_1 x - \phi_2 x^2 = 0$$

deben tener valor absoluto mayor que 1.

- Estas propiedades se generalizan a un $AR(p)$.

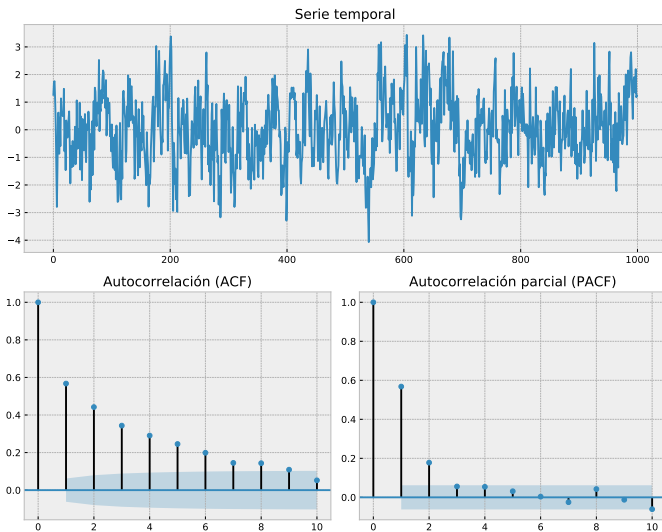


Figura: Modelo AR(2)

El operador Lag o Retardo

Operador Retardo

$$Lx_t = x_{t-1}, \quad L^2x_t = x_{t-2}, \quad \dots \quad L^kx_t = x_{t-k}$$

- Un proceso $AR(p)$:

$$x_t = \phi_1x_{t-1} + \phi_2x_{t-2} + \dots + \phi_px_{t-p} + a_t$$

- lo podemos escribir como:

$$\underbrace{(I - (\phi_1L + \phi_2L^2 + \dots + \phi_pL^p))}_{=\Phi(L)}x_t = a_t.$$

- Si las raíces del polinomio $\Phi(z) = (I - (\phi_1z + \phi_2z^2 + \dots + \phi_pz^p))$ tienen módulo mayor que 1: invertibilidad.

$$x_t = \Psi(L)a_t = a_t + \psi_1a_{t-1} + \psi_2a_{t-2} + \dots$$

Modelos MA(q)

$$MA(q)$$

- Son modelos de **media móvil**: **M**oving**A**verage, de orden q .
- Estos modelos intentan explicar la i -ésima observación a partir de las innovaciones anteriores.
- Según el número de observaciones anteriores consideradas es el orden q .

$$x_t = \mu + a_t - \theta_1 a_{t-1} \quad MA(1)$$

$$x_t = \mu + a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} \quad MA(2)$$

- a_t : innovación, es un ruido blanco.
- μ : es la media del proceso.

Propiedades de $MA(q)$

$$x_t = a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} - \cdots - \theta_q a_{t-q}.$$

- Son siempre (débilmente) estacionarias.
- Para un $MA(1)$,

$$\rho_1 = \frac{-\theta_1}{1 + \theta_1^2}, \quad \rho_h = 0, \quad h > 1.$$

- Para un $MA(q)$:


$$\rho_h = 0 \quad h > q$$

- La Función de Autocorrelación Parcial (PACF) no da mayor información.


Modelo MA(1)

```
theta = 0.6  
ar = np.r_[1, .0], ma = np.r_[1,-theta]  
ar1 = smt.arma_generate_sample(ar=ar, ma=ma, nsample=n)
```


Análisis gráfico de serie temporal



Autocorrelación




Autocorrelación parcial




Modelo MA(1)

```
theta = -0.6  
ar = np.r_[1, .0], ma = np.r_[1,-theta]  
ar1 = smt.arma_generate_sample(ar=ar, ma=ma, nsample=n)
```


Análisis gráfico de serie temporal



Autocorrelación



Autocorrelación parcial



Modelos ARMA(p, q)

$$ARMA(p, q)$$

- **A**uto **R**egresive **M**oving **A**verage.
- Son modelos que conjugan a los autorregresivos con los de media móvil.
- a_t : innovación, es un ruido blanco.

ARMA(1,2)

$$\underbrace{x_t - \phi_1 x_{t-1}}_{AR(1)} = \phi_0 + \underbrace{a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2}}_{MA(2)}$$

Series integradas

Si tenemos una serie de tiempo x_t , podemos:

- **diferenciarla:**

$$\Delta x_t = x_t - x_{t-1}$$



- y luego **integrarla:**

$$x_t = x_{t-1} + \Delta x_t.$$

Series $I(1)$

Una serie es **integrada de orden 1** si al diferenciarla **una vez** resulta estacionaria.

Ejemplos: precios de activos, índices, tasas de interés.



Raíces unitarias

- Si en un modelo AR(p) ocurre:

$$1 - \phi_1 - \phi_2 - \dots - \phi_p = 0$$

se dice que el proceso tiene un **raíz unitaria**.

- Los procesos con raíz unitaria no son estacionarios. Se pueden transformar en un proceso estacionarios diferenciando:

una vez	$x_t - x_{t-1} = \Delta x_t = (I - L)x_t$
dos veces	$(x_t - x_{t-1}) - (x_{t-1} - x_{t-2}) = (I - L)^2 x_t$
...	...

- Para testear la presencia de raíces unitarias: **Test ADF**: Augmented Dickey Fuller Test.

Modelos ARIMA

Modelo $ARIMA(p, d, q)$

Un proceso es un $ARIMA(p, d, q)$ si al diferenciarlo d veces resulta un $ARMA(p, q)$.

- Predicción en un $ARIMA(2, 1, 1)$:


$$x_t - x_{t-1} = \phi_0 + \phi_1 x_{t-1} + \phi_2 x_{t-2} - a_t - \theta_1 a_{t-1}$$

- Dadas las observaciones x_1, x_2, \dots, x_h :

$$\hat{x}_{h+1} = E[x_{h+1} \mid \text{observaciones anteriores}]$$

$$= x_h + \phi_0 + \phi_1 x_h + \phi_2 x_{h-1} - \theta_1 a_h$$

$$\text{Error} = a_{h+1}$$



La volatilidad como medida de riesgo

Los modelos presentados hasta el momento asumen que la volatilidad condicional es constante:

$$\text{Var}[a_t \mid F_{t-1}] = \sigma_a^2.$$

En la práctica se observan otras características:

- Clusters de volatilidad: períodos de alta volatilidad y otros de baja volatilidad.
- La volatilidad evoluciona de manera continua, los saltos son raros.
- La volatilidad no diverge a infinito, se mantiene en un rango: es frecuentemente **estacionaria**.
- Reacciona de manera diferente a una suba fuerte de precios a una baja fuerte de precios.

Modelos de heteroscedasticidad condicional


Supongamos que hemos ajustado una serie de tiempo de retornos de un activo a un determinado modelo ARIMA μ_t :

$$x_t - \mu_t = a_t,$$

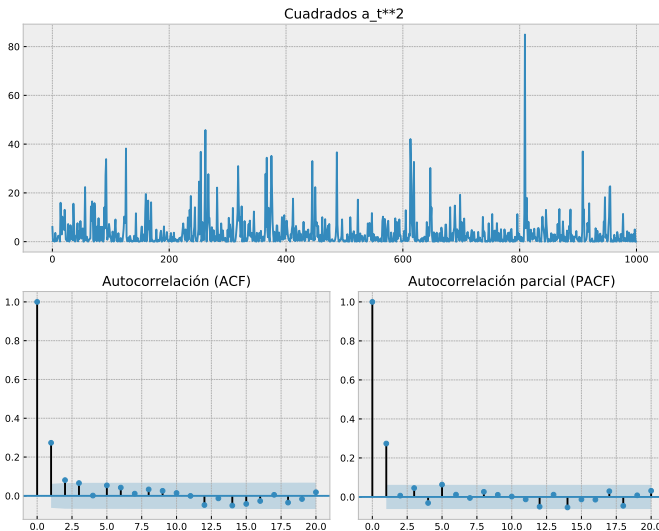
donde a_t son los errores.

- Los errores a_t no están serialmente correlacionados.
- Al analizar sus cuadrados a_t^2 se observa una dependencia lineal.

Residuos: ¿ruido blanco?



Residuos al cuadrado: dependencia lineal



Construcción del modelo

- Especificar un modelo para la media de los retornos de modo de eliminar la dependencia lineal: $x_t - \mu_t = a_t$, x_t un ARIMA(p,d,q).
- Usar los residuos a_t para testear un modelo autorregresivo de heteroscedasticidad condicional.
- Ajustar a un modelo de volatilidad: ARCH, GARCH.
- Existen otros modelos: EGARCH, TGARCH.

Modelos ARCH(p) y GARCH(p, q)

$$a_t = \sigma_t \epsilon_t,$$

- σ_t es la **volatilidad**.
- Se modela σ_t^2 .

$$\sigma_t^2 = \alpha_0 + \alpha_1 a_{t-1}^2 + \alpha_2 a_{t-2}^2 + \cdots + \alpha_p a_{t-p}^2$$

- La volatilidad depende del cuadrado de las innovaciones anteriores. Luego modela igual respuesta para innovaciones positivas que negativas.
- Responde muy lentamente a shocks aislados de los retornos.
- No provee una explicación de la fuente de aleatoriedad de la serie financiera.

Construcción de un ARCH(1)

```
a0 = 2
a1 = .5

y = w = np.random.normal(size=1000)
Y = np.empty_like(y)

for t in range(len(y)):
    y[t] = w[t] * np.sqrt((a0 + a1*y[t-1]**2))
```

Modelo GARCH(p, q)

$$x_t - \mu_t = a_t, \quad a_t = \sigma_t a_t,$$

- Se modela σ_t^2 :

$$\sigma_t^2 = \alpha_0 + \sum_{i=1}^p \alpha_i a_{t-i}^2 + \sum_{i=1}^q \beta_i \sigma_{t-i}^2$$

- Permite modelar clusters de volatilidad.
- No resuelve el problema de respuesta a innovaciones positivas y negativas.

Generación de un GARCH(1,1)

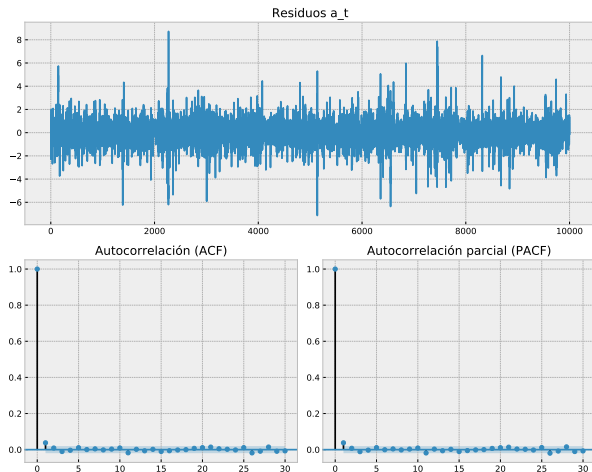
```
a0 = 0.2
a1 = 0.5
b1 = 0.3

n = 10000
w = np.random.normal(size=n)
eps = np.zeros_like(w)
sigsq = np.zeros_like(w)

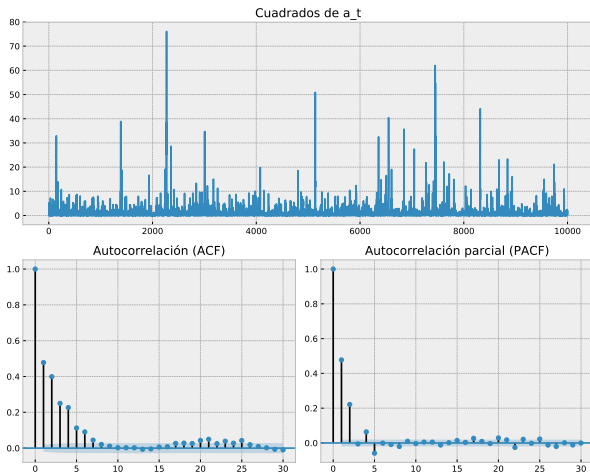
for i in range(1, n):
    sigsq[i] = a0 + a1*(eps[i-1]**2) + b1*sigsq[i-1]
    eps[i] = w[i] * np.sqrt(sigsq[i])

am = arch_model(eps).fit()
am.summary()
```

GARCH(1,1)



GARCH(1,1) - cuadrados



Resumen estadístico: GARCH(1,1)

Constant Mean - GARCH Model Results

```

=====
Dep. Variable:          y      R-squared:          -0.000
Mean Model:           Constant Mean  Adj. R-squared:        -0.000
Vol Model:            GARCH      Log-Likelihood:     -12237.3
Distribution:         Normal     AIC:                  24482.6
Method:              Maximum Likelihood  BIC:                  24511.4
                                           No. Observations:    10000
Date:                Sun, Sep 09 2018  Df Residuals:         9996
Time:                18:56:37          Df Model:              4
                                           Mean Model
=====

```

```

=====
              coef      std err          t      P>|t|      95.0% Conf. Int.
-----
mu          -6.7225e-03  6.735e-03      -0.998      0.318  [-1.992e-02,6.478e-03]
=====

```

Volatility Model

```

=====
              coef      std err          t      P>|t|      95.0% Conf. Int.
-----
omega          0.2021  1.043e-02      19.383  1.084e-83 [ 0.182, 0.223]
alpha[1]       0.5162  2.016e-02      25.611  1.144e-144 [ 0.477, 0.556]
beta[1]        0.2879  1.870e-02      15.395  1.781e-53 [ 0.251, 0.325]
=====

```